M4T3 | Detección de EPIs en Obras

Autor: Leonardo Freitez

Resumen Ejecutivo y Problema AECO

En el sector de la construcción, el incumplimiento del uso de Equipos de Protección Individual (EPIs) es una causa crítica de accidentes graves y fatalidades.
El presente proyecto implementa un modelo de Visión Computacional diseñado para auditar visualmente el cumplimiento de normativas de seguridad en tiempo real.

> **Criterio de Éxito:** Lograr un modelo con un *Recall alto* que minimice los Falsos Negativos, evitando bajo cualquier circunstancia que un trabajador desprotegido pase desapercibido ante el sistema.

Metodología: Dataset Roboflow

Clases Base

ELEMENTOS REGULARES

Identificación de objetos de uso obligatorio: **person** (operario), **helmet** (casco), **vest** (chaleco de alta visibilidad) y **security shoe** (calzado industrial).

Infracciones y Altura

RIESGOS ESPECÍFICOS

Etiquetas de negatividad: **no helmet** y **no vest**. Se incluye la clase especializada **harness** para trabajos en altura.

Estructura de Datos

PARTICIÓN DE MUESTRA

Se implementó un esquema: **70%** para el conjunto de Entrenamiento (Train), **20%** de Validación (Valid) y **10%** para Pruebas (Test).

Parámetros de Entrenamiento

Modelo Utilizado Se empleó la arquitectura YOLOv26 en su variante yolo26l.pt (Large), priorizando la detección precisa sobre la velocidad extrema.

Épocas (Epochs) El modelo procesó el conjunto de datos durante 50 ciclos completos para optimizar el aprendizaje.

Resolución Nativa Las imágenes de entrada fueron redimensionadas y procesadas a 640×640 píxeles.

Framework Base Ejecutado sobre el entorno de desarrollo Ultralytics versión 8.4.21.

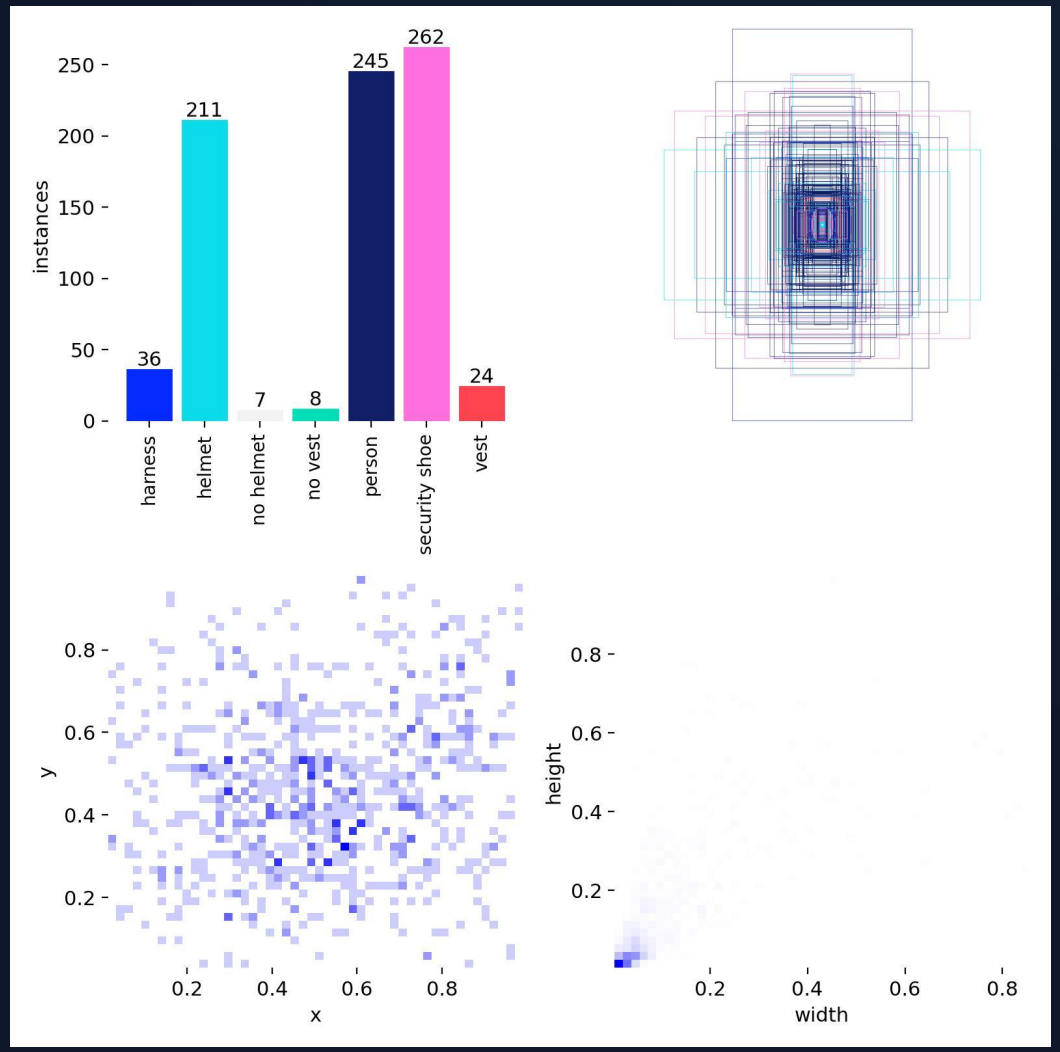

Resultados del Entrenamiento

Métricas consolidadas tras 50 épocas de procesamiento (YOLOv26l) sobre el conjunto de validación de Roboflow.

85.5%
PRECISIÓN (P)

44.0%
RECALL (R)

51.7%
MAP50

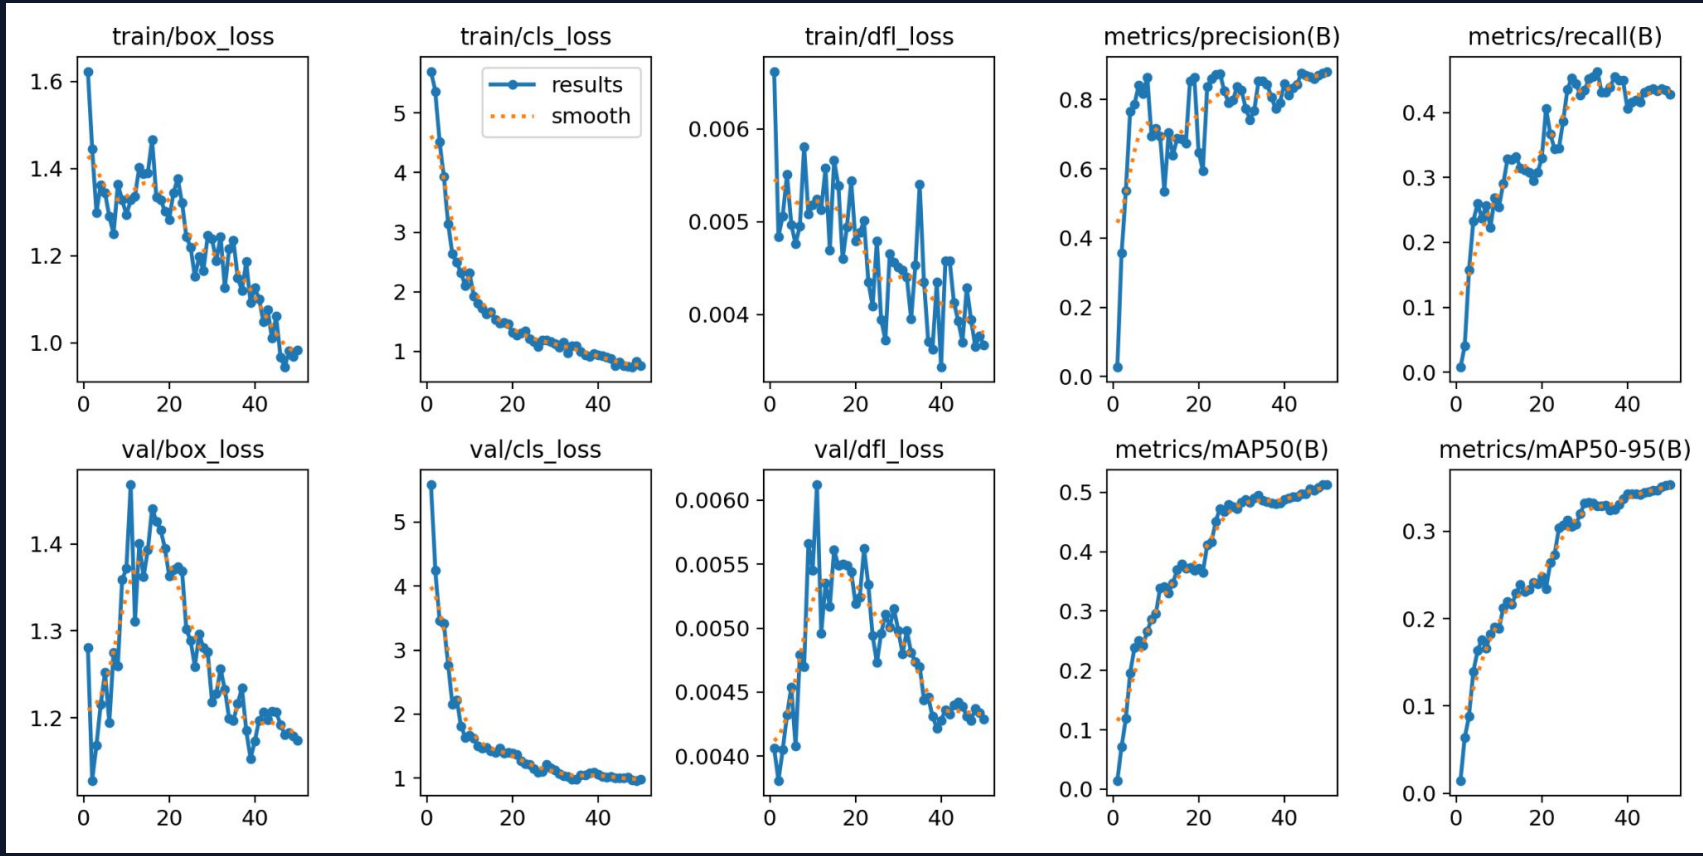

El modelo demuestra una **fiabilidad muy alta** cuando detecta un objeto (85.5% de precisión).

Sin embargo, el **Recall (44%)** indica que el algoritmo actualmente omite detectar un gran volumen de EPIs presentes en la escena.

Las clases helmet y person lideran en rendimiento general, mientras que la clase harness es la más deficiente y requiere de forma crítica más volumen de datos etiquetados.

Falsos Positivos (Alarmas Falsas)

- **Confusión de Color/Textura:** El modelo detectó elementos reflejantes en la estructura como si fueran la clase helmet.
- **Confusión de Prendas:** Chalecos ceñidos al cuerpo no fueron catalogados como la clase vest por falta de patrones evidentes.
- **Geometría de Fondo:** Cubos o herramientas en el suelo fueron clasificados como helmet por su forma circular.

Falsos Negativos (Riesgo Crítico)

- **Oclusión Severa** Trabajadores (person) fuertemente tapados por andamios o tubos metálicos no fueron detectados por el sistema.
- **Escala de Imagen** Pérdida de detección en la clase security shoe para operarios lejanos, provocado al redimensionar la resolución a 640px.
- **Bajo Contraste** Imposibilidad de segmentar la clase harness cuando el trabajador se encuentra sobre ropa oscura o escenarios sombreados.

Checklist de Gobernanza y Limitaciones

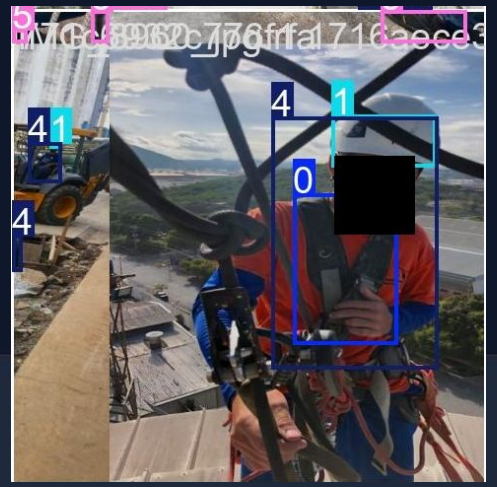

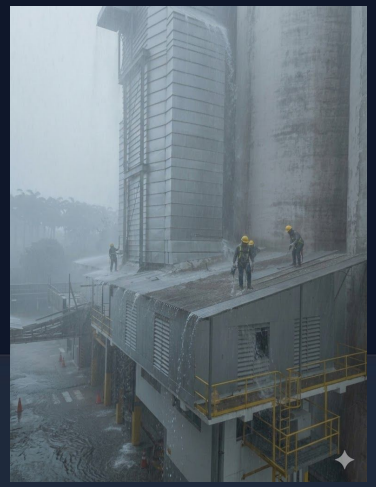

Privacidad de Datos (PII)

Entrenado evitando la focalización en rostros. **No emplea técnicas biométricas** y se exige ofuscación de matrículas en despliegues reales.

Condiciones Ambientales

El sistema disminuye radicalmente su precisión en condiciones de lluvia, niebla o visión nocturna sin iluminación de grado industrial.

Fatiga de Alarma

Por los Falsos Positivos, el umbral de confianza debe ser calibrado en obra para evitar que los operadores ignoren el sistema.